

Universidad Complutense de Madrid

Facultad de Comercio y Turismo

Máster de Formación Permanente en

DATA SCIENCE, BIG DATA & BUSINESS ANALYTICS

Inteligencia de reseñas de pacientes

Análisis de sentimiento y descubrimiento de temas
mediante NLP, con despliegue de un modelo productivizable

Trabajo Fin de Máster

Autora: Keyla Lisbeth López Chamorro

Tutores: Carlos Ortega y Santiago Mota

Septiembre de 2026

Índice

1	Resumen ejecutivo	2
2	Introducción y contexto de negocio	2
2.1	El problema	2
2.2	Objetivos	3
2.3	Preguntas de investigación	3
3	El conjunto de datos	3
3.1	Fuente, licencia y derechos de uso	3
3.2	Estructura y volumen	3
3.3	Calidad de los datos y limpieza aplicada	3
3.4	Limitaciones y consideraciones éticas	4
4	Análisis exploratorio	4
4.1	Contrastes estadísticos	5
4.2	Satisfacción por condición médica	5
5	Metodología	6
5.1	De la valoración a la etiqueta de sentimiento	6
5.2	Partición: por qué una división aleatoria engaña	6
5.3	Representación del texto	6
5.4	Las negaciones: un detalle que no lo era	7
5.5	Modelos evaluados	7
6	Resultados	8
6.1	El modelo no lineal no aporta: por qué	9
6.2	Dónde se equivoca el modelo	9
7	Interpretabilidad: por qué decide lo que decide	9
7.1	Explicación de un caso concreto	10
8	Temas y aspectos en las opiniones	10
8.1	Un hallazgo contraintuitivo	10
9	Productivización	12
9.1	Arquitectura	12
9.2	El modelo como instrumento de vigilancia	13
9.3	Del texto a la decisión	15
9.4	Un caso que el modelo no resuelve bien	17
10	Discusión orientada a negocio	18
11	Conclusiones y líneas futuras	18
11.1	Respuesta a las preguntas planteadas	18
11.2	Conclusiones técnicas	18
11.3	Limitaciones	19
11.4	Lecciones aprendidas	19
11.5	Líneas futuras	20
Anexo A	Código desarrollado y reproducibilidad	21
Anexo B	Léxico de aspectos	22
Anexo C	Análisis exploratorio ampliado	22
Anexo D	Resultados detallados	24

1 Resumen ejecutivo

Cuando un paciente deja de tomar un medicamento porque no lo soporta, rara vez se lo cuenta a su médico. Lo escribe en internet. Ese texto existe, es público y hoy está prácticamente sin explotar: nadie puede leer cientos de miles de opiniones a mano.

Este trabajo convierte esas opiniones en información accionable. Sobre **213.807 reseñas reales** de pacientes acerca de **3.658 medicamentos** y **836 condiciones médicas**, se ha construido un sistema que clasifica automáticamente el sentimiento de una reseña, descubre de qué hablan los pacientes y explica en qué se ha basado cada decisión.

Qué se ha conseguido. El modelo seleccionado —una máquina de vectores de soporte lineal sobre TF-IDF— alcanza un **F1 de 0,9540** y un **ROC-AUC de 0,9701**. Esa cifra no procede de una evaluación cómoda: el conjunto de prueba contiene **721 medicamentos que el modelo nunca vio durante el entrenamiento**, porque una división aleatoria le habría permitido memorizar el vocabulario de cada fármaco y habría producido una nota engañosamente alta (sección 5.2).

El hallazgo que cambia el enfoque. Cabría esperar que un paciente descontento sea el que habla de efectos secundarios. Los datos dicen que no: mencionarlos apenas altera la valoración media (7,16 frente a 7,12), pese a aparecer en el 63,5 % de las reseñas. Lo que sí discrimina es hablar de **eficacia**, con casi un punto de diferencia (7,58 frente a 6,69). Los pacientes toleran los efectos adversos cuando el medicamento funciona. Un sistema de vigilancia que se limitase a rastrear menciones de efectos secundarios estaría mirando al sitio equivocado.

Qué se entrega. El modelo no se queda en el cuaderno de análisis: se ha empaquetado en una aplicación que recibe una reseña nueva y devuelve, en segundos, la predicción con su probabilidad, los aspectos detectados y las palabras concretas que han inclinado la decisión.

Qué no resuelve. El sistema detecta el 96,3 % de las opiniones favorables pero solo el 82,2 % de las desfavorables, que son justamente las que importan. Por eso se plantea como un **filtro de priorización** —que ordena por urgencia un volumen inabarcable— y no como un sustituto del criterio humano.

Sobre las 36.327 reseñas del conjunto de prueba, el sistema localiza correctamente 7.135 opiniones desfavorables y explica por qué lo son. Revisar ese mismo volumen a mano, a dos minutos por reseña, exigiría más de 1.200 horas de trabajo.

2 Introducción y contexto de negocio

2.1 El problema

Cuando un paciente abandona un tratamiento, rara vez lo comunica a su médico: lo escribe en internet. Esa información existe, es pública y está sin explotar.

Las áreas de farmacovigilancia trabajan hoy con notificaciones formales de reacciones adversas, un canal fiable pero lento e infrautilizado. Las reseñas de pacientes ofrecen una señal complementaria: masiva, inmediata y espontánea. Su inconveniente es el formato —texto libre, sin estructura, con faltas de ortografía y jerga— que impide analizarlas con herramientas convencionales.

El coste de no hacerlo es doble. Por un lado, se pierde tiempo de reacción ante un problema de seguridad. Por otro, se desconoce qué mueve realmente la satisfacción del paciente, información valiosa para decidir sobre un tratamiento o priorizar la comunicación con el usuario.

2.2 Objetivos

1. **Clasificar** automáticamente el sentimiento de una reseña.
2. **Descubrir** los temas y aspectos predominantes en el corpus.
3. **Explicar** las predicciones de forma comprensible para negocio.
4. **Desplegar** el modelo en una aplicación que acepte reseñas nuevas.

2.3 Preguntas de investigación

P1 ¿Puede predecirse la satisfacción del paciente únicamente a partir del texto que escribe?

P2 ¿Generaliza el modelo a medicamentos que nunca ha visto?

P3 ¿Qué aspectos concentran la insatisfacción, y coinciden con los que cabría esperar?

La sección 8 muestra que la respuesta a P3 es contraintuitiva.

3 El conjunto de datos

3.1 Fuente, licencia y derechos de uso

Se emplea el *Drug Review Dataset* (Drugs.com), publicado en el UCI Machine Learning Repository (DOI 10.24432/C5SK5S) bajo licencia CC BY 4.0. Los autores autorizan su uso con fines de investigación, sin explotación comercial ni redistribución, y con cita del trabajo original [1]. El uso realizado en este TFM cumple íntegramente esas condiciones.

3.2 Estructura y volumen

Tabla 1: Variables del conjunto de datos.

Variable	Tipo	Descripción
drugName	Categórica	Nombre del medicamento (3.658 distintos)
condition	Categórica	Condición médica tratada (836 distintas)
review	Texto	Opinión libre del paciente
rating	Númerica	Valoración de 1 a 10
date	Fecha	Publicación, de feb. 2008 a dic. 2017
usefulCount	Númerica	Usuarios que la marcaron como útil

La longitud media de una reseña es de **84,7 palabras** (445,8 caracteres), suficiente para aplicar técnicas de NLP con garantías.

3.3 Calidad de los datos y limpieza aplicada

El fichero original presenta tres problemas que, de no corregirse, comprometerían el análisis. Se documentan aquí porque el diagnóstico de la calidad del dato es parte del trabajo, no un trámite previo.

1. **Codificación HTML doble.** Los apóstrofes aparecen como `'` y las reseñas van en vueltas en comillas duplicadas. Sin corregirlo, la tokenización fragmenta palabras como *don't* en unidades sin sentido.
2. **Filas corruptas.** **1.171 registros** contienen, en el campo `condition`, fragmentos de HTML procedentes del proceso de extracción original (por ejemplo, `"3</span> users found this comment helpful"`). Se eliminan.
3. **Duplicados exactos.** Se detectan y eliminan **85 reseñas** idénticas en texto, medicamento y condición. Aunque son pocas, su eliminación es imprescindible: una reseña repetida a ambos lados de la partición produciría fuga de información y métricas artificialmente optimistas.

Tras la limpieza se conservan **213.807 reseñas** de las 215.063 originales. Persisten 1.194 registros sin condición asignada, que se mantienen por ser válidos para el análisis de texto.

3.4 Limitaciones y consideraciones éticas

- **Sesgo de autoselección.** Quien escribe una reseña no es un paciente medio: suele hacerlo cuando el resultado ha sido muy bueno o muy malo. La sección 4 lo confirma empíricamente.
- **Ausencia de verificación clínica.** No hay diagnóstico confirmado ni seguimiento médico detrás de cada texto.
- **Privacidad.** Las reseñas son públicas y anónimas; no contienen identificadores de pacientes.
- **Uso responsable.** El sistema es una herramienta de apoyo al análisis agregado. **No constituye consejo médico** ni sustituye el criterio clínico, y así se advierte explícitamente en la aplicación.

4 Análisis exploratorio




Figura 1: Distribución de valoraciones y reparto por sentimiento.

El hallazgo más relevante del análisis exploratorio es que **la distribución de valoraciones es marcadamente bimodal**: las puntuaciones de 10 y de 1 concentran los dos mayores volúmenes, mientras que la zona intermedia está poco poblada. La valoración media es de **6,99** y la mediana de **8**, con una desviación típica de 3,28. El Anexo C amplía este análisis con el volumen por condición y medicamento, la longitud de las reseñas y la evolución temporal.

Esto no es un defecto del conjunto de datos: es información. Los pacientes escriben cuando tienen algo que celebrar o algo que denunciar. Tiene dos consecuencias directas para el proyecto:

justifica plantear el problema como clasificación binaria (sección 5.1) y advierte de que el modelo verá pocos ejemplos de opiniones tibias.

4.1 Contrastes estadísticos

Dos hipótesis intuitivas se han contrastado formalmente en lugar de darlas por buenas a partir de un gráfico.

¿Son más largas las reseñas negativas? La intuición dice que el descontento se explyaya más. Los datos dicen lo contrario: la mediana es de **86 palabras en las positivas** frente a **79 en las negativas**. La prueba de Mann-Whitney rechaza la igualdad de distribuciones con $p = 8,03 \times 10^{-90}$. La diferencia es pequeña en magnitud pero estadísticamente indiscutible: con 194.759 observaciones, casi cualquier diferencia resulta significativa, motivo por el que se reporta también el tamaño del efecto y no solo el p -valor.

¿Se perciben como más útiles las opiniones extremas? Sí. La correlación de Spearman entre valoración y número de votos de utilidad es $\rho = 0,28$, y las reseñas extremas (1, 2, 9 o 10) acumulan una media de **30,8 votos útiles** frente a **22,7** de las moderadas.

4.2 Satisfacción por condición médica




Figura 2: Condiciones con menor y mayor satisfacción declarada (mínimo 500 reseñas).

Las diferencias son grandes y clínicamente coherentes. En el extremo inferior aparecen *Vaginal Yeast Infection* (media 4,08 sobre 3.085 reseñas) y *Abnormal Uterine Bleeding* (4,38). En el superior, *Hyperhidrosis* (8,90), *Alcohol Dependence* (8,83) y *Smoking Cessation* (8,73).

El patrón sugiere que la satisfacción es alta cuando el tratamiento resuelve un problema concreto y verificable por el propio paciente, y baja en condiciones recurrentes donde el alivio es temporal.

5 Metodología

5.1 De la valoración a la etiqueta de sentimiento

Se traduce la valoración numérica en una etiqueta binaria: **positiva** si $\text{rating} \geq 7$ y **negativa** si $\text{rating} \leq 4$. La banda intermedia (5–6) se descarta por ambigua.

Esta decisión tiene un coste que conviene explicitar: se apartan **19.048 reseñas** (el 8,9% del total). A cambio, las dos clases representan opiniones inequívocas y la etiqueta resultante es fiable. El conjunto etiquetado queda en **194.759 reseñas**, con un **72,7% de positivas**: un desbalanceo moderado que obliga a no evaluar por *accuracy* y a compensar el peso de cada clase durante el entrenamiento.

5.2 Partición: por qué una división aleatoria engaña

Una partición aleatoria permitiría que el mismo medicamento apareciese en entrenamiento y en test. El modelo aprendería el vocabulario característico de ese fármaco —los efectos concretos que produce, cómo lo nombran los pacientes— y obtendría en test una nota que no reflejaría su capacidad real.

Se ha empleado por ello una **partición agrupada por medicamento**, con un reparto 80/20. El resultado: 158.432 reseñas de entrenamiento y 36.327 de test, con **721 medicamentos que aparecen únicamente en test**.

Evaluar sobre medicamentos nunca vistos produce cifras más bajas que una partición aleatoria, pero son las únicas que anticipan el comportamiento real del sistema cuando llegue al mercado un fármaco nuevo.

5.3 Representación del texto

Se emplea **TF-IDF** con unigramas y bigramas, produciendo una matriz de 158.432×195.397 . Las decisiones relevantes:

- **Parejas de palabras además de palabras sueltas.** Los bigramas capturan negaciones y expresiones compuestas ("*stopped taking*", "*weight gain*") que una palabra aislada pierde. Su peso en el modelo final lo confirma.
- **Descarte de los extremos del vocabulario.** Se eliminan los términos que aparecen en menos de cinco reseñas —erratas irrepetibles— y los presentes en más del 90 % del corpus, que no discriminan nada.
- **Amortiguación de las repeticiones.** Que una palabra aparezca diez veces en una reseña no la hace diez veces más relevante, y la ponderación lo tiene en cuenta.

Los valores exactos de cada parámetro están en el código (Anexo A).

El vectorizador se ajusta **únicamente sobre el conjunto de entrenamiento** y se reutiliza para todos los modelos. Nunca ve el test, por lo que no existe fuga de información.

5.4 Las negaciones: un detalle que no lo era

La configuración inicial empleaba la lista de palabras vacías (*stop words*) estándar de *scikit-learn*, que es lo habitual en clasificación de texto. Al inspeccionar el comportamiento del modelo apareció un problema serio: las frases «*it did work*» e «*it did not work*» —de sentido opuesto— recibían **exactamente la misma predicción**.

La causa es que esa lista contiene las nueve negaciones del inglés (*not, no, never, nor, none, cannot, nothing, nowhere, neither*). Al descartarlas, ambas frases se reducen a los mismos rasgos y se vuelven indistinguibles.

El criterio es razonable en tareas de clasificación temática, donde las negaciones aportan poco. En **análisis de sentimiento es exactamente al revés**: la negación es con frecuencia lo único que separa una opinión favorable de una desfavorable.

Se redefinió por ello la lista conservando las negaciones. El efecto va mucho más allá del caso anecdótico:

Tabla 2: Efecto de conservar las negaciones (Regresión Logística, misma partición agrupada por medicamento).

Lista de palabras vacías	F1	F1 macro	ROC-AUC
Estándar (descarta negaciones)	0,9446	0,8900	0,9647
Conservando negaciones	0,9493	0,8992	0,9698

La mejora más notable se produce en el **F1 macro** (+0,9 puntos), es decir, justo en la detección de la clase minoritaria, que era la principal debilidad del sistema. Con la lista estándar, «*it did work*» e «*it did not work*» reciben ambas un 0,2 % de probabilidad de ser positivas: son indistinguibles. Tras el cambio, la primera obtiene un 86,4 % y la segunda menos del 0,1 %.

Las opciones por defecto de una librería llevan implícitas decisiones de diseño pensadas para otra tarea. La lista de palabras vacías estándar está pensada para clasificación temática; aplicarla sin revisarla a un problema de sentimiento destruye precisamente la información que más importa.

5.5 Modelos evaluados

Tabla 3: Técnicas evaluadas, con sus bondades y debilidades.

Técnica	Bondades	Debilidades
Baseline	Referencia mínima imprescindible	Sin capacidad predictiva
Naive Bayes (Complement)	Muy rápido; corrige el sesgo del NB ante clases desbalanceadas	Asume independencia entre términos, falsa en lenguaje natural
Regresión Logística	Interpretable; sus coeficientes explican la decisión	Solo capta relaciones lineales
SVM lineal	Muy eficaz en alta dimensión	No da probabilidades sin calibrar; calibrar triplica el coste
Random Forest (sobre LSA)	Capta interacciones no lineales	Exige reducir dimensionalidad; pierde interpretabilidad

Random Forest merece una nota. Aplicarlo directamente sobre 195.397 columnas dispersas resulta inviable en tiempo y rinde mal. Se le antepone una reducción de dimensionalidad a 150

componentes mediante Análisis Semántico Latente, que es la práctica habitual para combinar modelos de árboles con representaciones de texto. Se limita además la profundidad de los árboles a 14 niveles: sin ese límite el entrenamiento supera los cinco minutos sin mejora apreciable.

Conviene anticipar aquí un dato que resultará decisivo en los resultados: esas 150 componentes explican únicamente el **8,4% de la varianza** original. La compresión es agresiva y, como se verá, tiene un coste.

6 Resultados

Tabla 4: Métricas sobre el conjunto de test (36.327 reseñas, 721 medicamentos no vistos).

Modelo	Accuracy	Precisión	Recall	F1	F1 macro	ROC-AUC
Baseline (clase mayoritaria)	0,7610	0,7610	1,0000	0,8643	0,4321	0,5000
Random Forest (sobre LSA)	0,8602	0,9251	0,8883	0,9063	0,8156	0,9121
Naive Bayes (Complement)	0,8687	0,9401	0,8837	0,9111	0,8302	0,9314
Regresión Logística	0,9241	0,9654	0,9337	0,9493	0,8992	0,9698
SVM lineal	0,9294	0,9451	0,9632	0,9540	0,9008	0,9701




Figura 3: Comparativa de modelos sobre el conjunto de test.

El baseline ilustra por qué no basta con la *accuracy*. Predecir siempre "positivo" alcanza un F1 de 0,8643, una cifra aparentemente buena que corresponde a un modelo sin ningún valor: su ROC-AUC es 0,5, el del azar. Toda comparación honesta debe apoyarse en ROC-AUC y F1-macro.

La **SVM lineal** obtiene el mejor F1 (0,9540) y ROC-AUC (0,9701). La Regresión Logística queda muy cerca (0,9493 y 0,9698) con una diferencia prácticamente irrelevante en la práctica, lo que resulta útil: si se priorizase la interpretabilidad directa, cambiar a Regresión Logística costaría menos de medio punto de F1.

La validación cruzada de 5 particiones sobre el entrenamiento confirma la estabilidad: $F1 = 0,9423 \pm 0,0007$.

6.1 El modelo no lineal no aporta: por qué

Random Forest queda claramente por detrás (F1 de 0,9063 y ROC-AUC de 0,9121), al nivel del Naive Bayes y a casi seis puntos de ROC-AUC de los modelos lineales. El resultado merece explicación, porque contradice la intuición de que un modelo más flexible debería rendir mejor.

La causa no es el algoritmo, sino la representación que se ve obligado a usar. Random Forest no puede operar sobre 195.397 columnas dispersas, de modo que antes hay que comprimir el texto a 150 componentes mediante SVD, y esa compresión **retiene apenas el 8,4% de la varianza**. El modelo trabaja, por tanto, con una versión muy empobrecida de la información: pierde exactamente los términos poco frecuentes pero muy discriminantes (*miracle*, *useless*, *ruined*) sobre los que se apoyan los modelos lineales.

En clasificación de texto, la capacidad de un modelo para captar relaciones no lineales importa menos que su capacidad para trabajar directamente sobre una representación dispersa de alta dimensión. La flexibilidad del algoritmo no compensa la información destruida al comprimir.

Su peor comportamiento se concentra además en la clase minoritaria: la precisión sobre reseñas negativas cae a 0,6842, frente al 0,8752 de la SVM. Dicho de otro modo, una de cada tres alertas que generaría sería falsa.

6.2 Dónde se equivoca el modelo

Las métricas agregadas esconden un desequilibrio importante entre clases:

Tabla 5: Rendimiento por clase del modelo seleccionado (SVM lineal).

Clase	Precisión	Recall	F1	Casos
Negativa	0,8752	0,8217	0,8476	8.683
Positiva	0,9451	0,9632	0,9540	27.644

El modelo es notablemente peor detectando reseñas negativas: recupera el 82,2% de ellas frente al 96,3% de las positivas. Dicho de otro modo, **el 17,8 % de las opiniones desfavorables pasa desapercibido**. El F1 macro (0,9008) refleja esta realidad mucho mejor que el F1 global. Las curvas ROC y el desglose por clase de todos los modelos están en el Anexo D.

Esto importa, y mucho, para el caso de uso: en farmacovigilancia el error caro es precisamente el falso negativo, la señal de alarma que no se detecta. La sección 9 explica cómo la aplicación mitiga este problema mediante un umbral de alerta configurable en lugar del 0,5 por defecto.

7 Interpretabilidad: por qué decide lo que decide

Como la SVM calibrada no expone coeficientes directamente interpretables, la explicabilidad global se calcula sobre la Regresión Logística, cuyo rendimiento es equivalente. Los términos aprendidos son un buen indicio de que el modelo capta señal real y no artefactos:

- **Hacia negativo:** *not recommend*, *not worth*, *worse*, *don't recommend*, *disappointed*, *no improvement*, *wouldn't recommend*, *worst*, *does nothing*, *no relief*.




Figura 4: Términos con mayor peso en la decisión del modelo.

- **Hacia positivo:** *love, amazing, miracle, works, saved, changed life, great, best, no effects.*

Dos observaciones. La primera, que la mayoría de los términos más informativos son **bigramas**, lo que valida la decisión de incluirlos. La segunda, más relevante: **seis de los diez rasgos más negativos contienen una negación** (*not recommend, no improvement, no relief*), y entre los positivos aparece *no effects* —de «no side effects»—. Esto confirma que conservar las negaciones (sección 5.4) no fue un ajuste menor: las negaciones son la señal más discriminante del corpus.

7.1 Explicación de un caso concreto

Sobre una reseña real de **Apixaban** con valoración 1, el modelo asigna una probabilidad de sentimiento positivo de **0,044**, es decir, la clasifica correctamente como negativa con alta confianza. Los términos que más pesan en esa decisión son *stop, developed, taking* y *flu*, coherentes con un relato de abandono del tratamiento por efectos adversos.

Este nivel de explicación es lo que permite que un revisor humano confíe en el sistema: no recibe un veredicto opaco, sino un veredicto con sus motivos.

8 Temas y aspectos en las opiniones

La factorización matricial no negativa (NMF) sobre TF-IDF identifica ocho temas sin ninguna supervisión. Su nitidez es notable: emergen áreas terapéuticas reconocibles sin haberlas definido.

8.1 Un hallazgo contraintuitivo

El análisis por aspectos, construido sobre un léxico definido explícitamente (véase Anexo B), arroja el resultado más interesante del trabajo.

Cabría esperar que mencionar efectos secundarios fuese señal de insatisfacción. **No lo es**: la valoración media apenas varía (7,16 frente a 7,12) pese a que el aspecto aparece en el 63,5% de las reseñas. Lo que sí discrimina es hablar de **eficacia**, con una diferencia de casi un punto (7,58 frente a 6,69).




Figura 5: Temas descubiertos mediante NMF y su polaridad.

Tabla 6: Temas descubiertos y proporción de reseñas positivas.

Tema	Términos principales	% positivas
Eficacia general	works, great, medicine works	92,7%
Ansiedad y depresión	anxiety, life, depression, panic	83,8%
Sueño	sleep, night, asleep, hours	77,3%
Peso	weight, gain, lost, pounds	77,0%
Dolor crónico	pain, relief, severe, chronic	72,6%
Dermatología	acne, skin, face, clear	72,5%
Posología	day, days, took, taking	65,6%
Anticoncepción	period, birth control, pill	63,1%

Tabla 7: Aspectos mencionados y su relación con la valoración.

Aspecto	% reseñas	Valoración si lo menciona	Si no
Eficacia	51,3%	7,58	6,69
Efectos secundarios	63,5%	7,16	7,12
Posología y administración	43,5%	7,18	7,11
Coste y acceso	7,6%	7,37	7,12

Los pacientes toleran los efectos secundarios cuando el medicamento funciona. Lo que determina la satisfacción no es la ausencia de efectos adversos, sino la percepción de eficacia. Un sistema de alerta que se limitase a buscar menciones de efectos secundarios generaría un enorme volumen de falsos positivos.




Figura 6: Menciones de efectos secundarios frente a satisfacción, por condición.

El cruce por condición señala dónde mirar. **Birth Control** destaca como el caso más preocupante: con 33.573 reseñas —el mayor volumen del corpus— registra la valoración media más baja del grupo (6,18), un 69,6% de menciones de efectos secundarios y solo un 31,3% de menciones de eficacia. Es exactamente el perfil que justificaría una revisión: mucho volumen, baja satisfacción y escasa percepción de que el tratamiento funcione.

9 Productivización

Un modelo que solo vive en un cuaderno de análisis no aporta valor. El modelo entrenado se ha empaquetado en una **aplicación web** con dos vistas, que responden a dos preguntas distintas del día a día de un analista:

- **Perfil del medicamento** (vista principal). ¿Qué está pasando con este fármaco? Reúne todas sus reseñas y devuelve satisfacción, aspectos que preocupan a los pacientes, evolución temporal y —aplicando el modelo a cada reseña— cuáles conviene revisar primero.
- **Analizar una reseña**. ¿Qué hago con este texto que acaba de llegar? Clasifica una opinión nueva y explica la decisión.

9.1 Arquitectura

La solución se serializa como un *pipeline* único que encapsula el vectorizador y el clasificador. Esto garantiza que el texto recibido en producción atraviese exactamente las mismas transformaciones que durante el entrenamiento, eliminando la principal fuente de errores en el despliegue de modelos de NLP.

Sobre él, una interfaz en **Streamlit** expone tres funciones: predicción con probabilidad asociada, detección de aspectos y explicación local mediante LIME.

9.2 El modelo como instrumento de vigilancia

La vista de perfil es donde el modelo deja de ser un clasificador y pasa a ser una herramienta de trabajo. Para el fármaco seleccionado, el sistema puntúa todas sus reseñas y las ordena por probabilidad de ser negativas. El analista no lee 4.925 opiniones: lee las que el modelo sitúa arriba.



Figura 7: Perfil de *Levonorgestrel*. La herramienta resume 4.925 reseñas en cuatro indicadores, los contrasta con la media del corpus y desglosa de qué hablan los pacientes con la valoración asociada a cada aspecto.

El valor de hacerlo con el modelo, y no ordenando por la valoración que el paciente declaró, se ve en un caso real de *Levonorgestrel*. Entre las reseñas que el modelo sitúa como más críticas aparece una con **valoración declarada de 6 sobre 10** —una nota intermedia que ningún sistema de alertas basado en estrellas señalaría— cuyo texto dice simplemente «*It did not work*». El modelo le asigna una probabilidad de sentimiento positivo del 0,1 %.

Ordenar por la puntuación numérica deja escapar las reseñas cuya valoración es tibia pero cuyo contenido es claramente negativo. Leer el texto —que es lo que hace el modelo— recupera esas señales.



Figura 8: Condiciones tratadas y evolución de la valoración media. El descenso sostenido desde 2014 es el tipo de señal que justifica abrir una revisión.




Figura 9: Reseñas de *Levonorgestrel* ordenadas por el modelo. La segunda —«It did not work»— tiene una valoración declarada de 6 sobre 10, pero el modelo la sitúa entre las más críticas del medicamento.

9.3 Del texto a la decisión

La segunda vista cubre el otro escenario: una reseña nueva que acaba de llegar. El analista la pega y el sistema devuelve el sentimiento previsto con su probabilidad, los aspectos detectados y los términos que han inclinado la decisión.



Figura 10: Reseña desfavorable. El modelo asigna una probabilidad de sentimiento positivo del 0,0 %, dispara la alerta por situarse bajo el umbral del 35 % y detecta el aspecto de efectos secundarios.



Figura 11: Explicación de la reseña desfavorable. Los términos decisivos son *worst* (−0,063), *severe* (−0,062) y *unbearable* (−0,059). Los pesos positivos corresponden a palabras vacías (*the*, *and*, *out*) y son un orden de magnitud menores.

La aplicación incorpora un **umbral de alerta configurable** (0,35 por defecto en lugar del 0,5 habitual). Esta decisión responde directamente a la debilidad identificada en la sección de errores: al elevar la sensibilidad hacia la clase negativa se recuperan reseñas desfavorables que un umbral neutro dejaría escapar, a costa de revisar algunos falsos positivos. En farmacovigilancia, ese intercambio es claramente favorable.



Figura 12: Reseña favorable. Además de la predicción (97,7%), la aplicación identifica tres aspectos distintos —eficacia, efectos secundarios y posología— en un mismo texto.




Figura 13: Explicación de la reseña favorable. *works* y *finally* aportan +0,140 cada uno. Conviene fijarse en el lado contrario: *pain* (-0,038) y *relief* (-0,035) empujan hacia negativo pese a aparecer aquí en una frase de mejoría. El modelo asocia el vocabulario del dolor con la queja, no con su alivio.

9.4 Un caso que el modelo no resuelve bien

La herramienta también sirve para exponer los límites del sistema. La figura 14 muestra una reseña mixta: la paciente reconoce que el medicamento funciona, pero el aumento de peso le resulta difícil de sobrellevar y se plantea abandonar el tratamiento.



Figura 14: Reseña mixta. El modelo la clasifica como positiva con un 96,2 % de confianza pese a que la paciente se plantea abandonar el tratamiento.




Figura 15: Explicación de la reseña mixta. El peso de *works* (+0,185) domina sobre todos los términos de duda juntos. Nótese además que *pros* se contabiliza como señal negativa y *cons* como positiva: LIME mide asociaciones estadísticas del corpus, no el significado de las palabras.

El modelo la clasifica como positiva con un 96,2 % de confianza. La explicación revela por qué: el término *works* aporta un peso de +0,185, más del doble que el mayor de los términos que expresan duda (*sure*, -0,070; *continue*, -0,050; *pros*, -0,048). El sistema detecta el vocabulario de eficacia, pero no la reserva que lo acompaña.

Este caso concreta la limitación cuantificada en la sección 6.2: el modelo detecta peor lo negativo, y falla especialmente cuando la insatisfacción se expresa sin palabras negativas explícitas. Es el argumento que justifica bajar el umbral de alerta por debajo de 0,5 y mantener siempre a un revisor humano en el proceso.

10 Discusión orientada a negocio

Volumen procesable. Sobre las 36.327 reseñas de test, el sistema identifica correctamente 7.135 de las 8.683 opiniones negativas. Una revisión manual equivalente, a un ritmo conservador de dos minutos por reseña, supondría más de 1.200 horas de trabajo.

Dónde poner el foco. El análisis por aspectos redirige el esfuerzo de vigilancia: rastrear menciones de efectos secundarios es ineficiente porque aparecen en el 63,5% de las reseñas sin correlación con la insatisfacción. La señal útil está en la percepción de eficacia.

El coste del error. Con la configuración por defecto, el 17,8% de las reseñas negativas pasa desapercibido. El sistema debe entenderse como un **filtro de priorización**, no como un sustituto del criterio humano: su valor está en ordenar por urgencia un volumen inabarcable, no en decidir por sí solo.

Respuesta a las preguntas planteadas. P1: sí, el texto por sí solo predice la satisfacción con un ROC-AUC de 0,9701. P2: sí, y esa cifra se obtiene precisamente sobre medicamentos nunca vistos. P3: los aspectos que concentran la insatisfacción no son los esperados, como se ha discutido.

11 Conclusiones y líneas futuras

11.1 Respuesta a las preguntas planteadas

El trabajo partía de tres preguntas. Estas son las respuestas que arrojan los datos.

P1. ¿Puede predecirse la satisfacción del paciente solo con el texto? Sí, y con margen. Sin conocer el medicamento, la condición ni la edad del paciente —únicamente lo que escribe— el modelo alcanza un ROC-AUC de 0,9701. La señal está en el lenguaje, no en los metadatos.

P2. ¿Generaliza a medicamentos que nunca ha visto? Sí, y esta es la conclusión de la que más me fío, porque es la que se puso más difícil de demostrar. El conjunto de prueba está formado por 721 fármacos ausentes del entrenamiento. El modelo no ha memorizado vocabularios concretos: ha aprendido cómo se expresa la satisfacción.

P3. ¿Son los efectos secundarios lo que concentra la insatisfacción? No. Y es el resultado más útil del trabajo precisamente porque contradice la intuición de partida. Lo que separa a un paciente satisfecho de uno insatisfecho no es sufrir efectos adversos, sino percibir que el tratamiento funciona.

11.2 Conclusiones técnicas

1. **La representación importa más que el algoritmo.** Random Forest, el único modelo capaz de captar relaciones no lineales, queda casi seis puntos de ROC-AUC por detrás de una regresión logística. No por ser peor algoritmo, sino porque para poder ejecutarse necesita una

compresión que conserva el 8,4 % de la varianza y destruye los términos poco frecuentes pero muy discriminantes.

2. **La partición decide la credibilidad de las cifras.** Agrupar por medicamento en lugar de dividir al azar es la decisión metodológica con más impacto de todo el trabajo: produce números más bajos, pero son los únicos que anticipan el comportamiento real del sistema.
3. **Sin un *baseline* trivial, las métricas engañan.** Predecir siempre «positivo» ya da un F1 de 0,8643 con un ROC-AUC de 0,5. Cualquier lectura honesta exige mirar F1-macro y ROC-AUC.
4. **La explicabilidad no es un adorno.** Es lo que permite auditar el modelo. Comprobar que los términos de mayor peso son *worst*, *useless* o *stopped taking* —y no artefactos del corpus— es lo que da confianza para usarlo.

11.3 Limitaciones

- **El modelo detecta peor lo negativo**, que es lo que más importa: el 17,8 % de las reseñas desfavorables pasa desapercibido. Se mitiga con el umbral de alerta, pero no se elimina.
- **No entiende la reserva sin palabras negativas.** La sección 9 muestra un caso real: una paciente que se plantea abandonar el tratamiento es clasificada como positiva con un 96,2 % de confianza, porque dice que el medicamento «funciona».
- **El léxico de aspectos detecta menciones, no polaridad.** «*no side effects*» cuenta como mención de efectos secundarios, lo que probablemente explica en parte que ese aspecto no discrimine.
- **Los datos tienen sesgo de autoselección.** Quien escribe una reseña no es un paciente medio: la distribución bimodal de valoraciones lo confirma. Las conclusiones describen a quien opina, no a toda la población de pacientes.

11.4 Lecciones aprendidas

La decisión técnica con mayor impacto no fue la elección del algoritmo, sino la **estrategia de partición**. Comprobar que una división aleatoria inflaba las métricas obligó a rehacer la evaluación y produjo cifras más bajas, pero defendibles.

La segunda lección llegó con Random Forest. Entrenarlo directamente sobre la matriz dispersa resultó inviable, y la reducción necesaria para hacerlo ejecutable acabó siendo la causa de su peor rendimiento. Es un buen recordatorio de que una restricción computacional puede convertirse, sin advertirlo, en una limitación metodológica.

La tercera, y la más instructiva, fue el asunto de las negaciones. Descubrir que el modelo no distinguía «*it did work*» de «*it did not work*» obligó a revisar una opción que había aceptado sin cuestionar, por venir por defecto en la librería. Corregirla mejoró el F1 macro en 0,9 puntos. La lección: los valores por defecto encierran supuestos, y conviene comprobar si esos supuestos encajan con el problema que uno tiene entre manos.

Por último, medir siempre contra un *baseline* trivial evitó un error de lectura: un F1 de 0,86 parecía un buen resultado hasta comprobar que se alcanzaba prediciendo siempre la misma clase.

11.5 Líneas futuras

- **Modelos basados en Transformers.** Conservar las negaciones mitiga el problema, pero no lo resuelve: el modelo sigue sin entender el alcance de una negación ni la ironía. Un modelo tipo BERT, que procesa la frase completa en lugar de una bolsa de términos, es la vía natural.
- **Umbral optimizado por coste.** Ajustar el umbral maximizando una función de coste explícita en lugar de fijarlo heurísticamente.
- **Detección de emergentes.** Vigilar la aparición de términos nuevos asociados a un medicamento como señal temprana de un efecto adverso no documentado.
- **Extensión multilingüe,** para aplicar el sistema a corpus en español.

Referencias

- [1] Gräßer, F., Kallumadi, S., Malberg, H., Zaunseder, S. (2018). *Aspect-Based Sentiment Analysis of Drug Reviews Applying Cross-Domain and Cross-Data Learning*. International Conference on Digital Health, 121–125.
- [2] Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825–2830.
- [3] Ribeiro, M. T., Singh, S., Guestrin, C. (2016). “*Why Should I Trust You?*”: *Explaining the Predictions of Any Classifier*. KDD 2016, 1135–1144.
- [4] Lee, D. D., Seung, H. S. (2001). *Algorithms for Non-negative Matrix Factorization*. NIPS 13, 556–562.

Anexo A Código desarrollado y reproducibilidad

El código completo se encuentra en el siguiente repositorio público:

<https://github.com/klopez-1601/tfm-inteligencia-resenas-pacientes>

El repositorio contiene el código, la memoria, las figuras y las métricas. No incluye la carpeta `data/`: la licencia del conjunto de datos permite su uso con fines de investigación pero **no su redistribución**, por lo que el README indica cómo descargarlo desde la fuente original.

Fichero	Contenido
<code>src/config.py</code>	Rutas, constantes, carga y limpieza de datos
<code>src/eda.py</code>	Fase 1: análisis descriptivo y contrastes
<code>src/modelado.py</code>	Fase 2: vectorización y comparativa de modelos
<code>src/topics_explicabilidad.py</code>	Fase 3: temas, aspectos y LIME
<code>src/app.py</code>	Fase 4: aplicación de productivización

Reproducción completa en cuatro órdenes:

```
pip install -r requirements.txt
python src/eda.py
python src/modelado.py
python src/topics_explicabilidad.py
```

La aplicación se levanta con una orden adicional:

```
streamlit run src/app.py
```

Se ejecuta en local y no requiere despliegue en ningún servidor. El vídeo que acompaña a esta memoria la muestra en funcionamiento, de modo que su comportamiento puede verificarse sin necesidad de instalar nada. El modelo entrenado se incluye en el repositorio (`modelos/`), por lo que la pestaña de análisis de reseñas funciona nada más clonar; la de perfil del medicamento necesita además el conjunto de datos, que debe descargarse de la fuente original por las condiciones de licencia descritas en la sección 3.1.

Todos los procesos aleatorios emplean la semilla fija `RANDOM_STATE = 42`: partición, submuestreos, NMF, SVD, Random Forest y LIME. Las métricas se escriben en `resultados/metricas/*.json`, de modo que **cada cifra de esta memoria es trazable hasta una ejecución concreta** y puede verificarse volviendo a ejecutar el código. Esa ejecución se realizó con Python 3.10, pandas 2.3.3, numpy 2.2.6 y scikit-learn 1.7.2. Con versiones posteriores el código funciona sin cambios, pero al cargar el modelo ya entrenado las probabilidades individuales pueden desplazarse unos puntos (la reseña mixta de la sección 9.3 obtiene un 90,9 % con scikit-learn 1.7.2 y un 96,2 % con 1.9.1, que es la versión con la que se tomaron las capturas). Ninguna clasificación ni conclusión cambia, y las métricas globales se reproducen reentrenando el modelo.

Anexo B Léxico de aspectos

El análisis de la sección 8 se apoya en un léxico definido de forma explícita. Se optó por esta vía —y no por un diccionario automático— porque el objetivo era medir aspectos concretos y accionables para farmacovigilancia, no obtener categorías genéricas.

La búsqueda se realiza sobre el texto en minúsculas mediante expresiones regulares con delimitadores de palabra (`\b`), de forma que *"pain"* no active una coincidencia dentro de *"painting"*.

Aspecto	Términos
Eficacia	work, works, worked, effective, helped, help, relief, improve, improved, better, cured, results
Efectos secundarios	side, effects, nausea, headache, dizzy, dizziness, weight, gain, anxiety, insomnia, tired, fatigue, pain, sick, vomiting, rash, depression
Posología y administración	dose, dosage, mg, pill, pills, tablet, injection, daily, twice, morning, night, taper, withdrawal
Coste y acceso	price, cost, expensive, insurance, cheap, afford, pharmacy, generic, coupon

Limitación conocida. El léxico detecta la *mención* de un aspecto, no su *polaridad*: la frase *"no side effects"* cuenta como mención de efectos secundarios. Esta es, muy probablemente, una de las razones por las que dicho aspecto apenas discrimina entre reseñas satisfechas e insatisfechas (Tabla 6). Un análisis de sentimiento basado en aspectos, con detección de negación, es la extensión natural de este trabajo.

Anexo C Análisis exploratorio ampliado




Figura 16: Condiciones y medicamentos con mayor volumen de reseñas.




Figura 17: Distribución de la longitud de la reseña según el sentimiento. Base gráfica del contraste de Mann-Whitney de la sección 4.1.




Figura 18: Evolución del volumen de reseñas y de la valoración media por trimestre, de 2008 a 2017.

Anexo D Resultados detallados




Figura 19: Curvas ROC de los modelos evaluados.

Informe de clasificación por clase

Complementa la Tabla 4 con el detalle de los dos modelos extremos de la comparativa.

Modelo	Clase	Precisión	Recall	F1	Casos
SVM lineal	Negativa	0,8752	0,8217	0,8476	8.683
	Positiva	0,9451	0,9632	0,9540	27.644
Random Forest (LSA)	Negativa	0,6842	0,7709	0,7250	8.683
	Positiva	0,9251	0,8883	0,9063	27.644

El contraste es revelador: sobre la clase positiva ambos modelos son comparables, pero sobre la negativa —la que importa— Random Forest pierde 19 puntos de precisión. Confirma que la diferencia entre ambos no está en la capacidad de clasificar en general, sino en detectar la señal minoritaria.

Ficheros de métricas

Fichero	Contenido
eda_resumen.json	Estadísticos descriptivos y contrastes
modelado_resultados.json	Métricas de los 5 modelos y coeficientes
temas_y_explicabilidad.json	Temas NMF, aspectos y casos LIME
ablacion_negaciones.json	Efecto de las negaciones (sección 5.4) y varianza SVD