

Universidad Complutense de Madrid

Facultad de Comercio y Turismo

Máster de Formación Permanente en

DATA SCIENCE, BIG DATA & BUSINESS ANALYTICS

Inteligencia de reseñas de pacientes

Análisis de sentimiento y descubrimiento de temas
mediante NLP, con despliegue de un modelo productivizable

Trabajo Fin de Máster

Autora: Keyla Lisbeth López Chamorro

Tutores: Carlos Ortega y Santiago Mota

Septiembre de 2026

Índice

1	Resumen ejecutivo	2
2	Introducción y contexto de negocio	2
2.1	El problema	2
2.2	Objetivos	2
2.3	Preguntas de investigación	3
3	El conjunto de datos	3
3.1	Fuente, licencia y derechos de uso	3
3.2	Estructura y volumen	3
3.3	Calidad de los datos y limpieza aplicada	3
3.4	Limitaciones y consideraciones éticas	4
4	Análisis exploratorio	4
4.1	Contrastes estadísticos	4
4.2	Satisfacción por condición médica	5
5	Metodología	5
5.1	De la valoración a la etiqueta de sentimiento	5
5.2	Partición: por qué una división aleatoria engaña	6
5.3	Representación del texto	6
5.4	Modelos evaluados	6
6	Resultados	7
6.1	El modelo no lineal no aporta: por qué	8
6.2	Dónde se equivoca el modelo	8
7	Interpretabilidad: por qué decide lo que decide	8
7.1	Explicación de un caso concreto	9
8	Temas y aspectos en las opiniones	9
8.1	Un hallazgo contraintuitivo	10
9	Productivización	11
9.1	Arquitectura	11
9.2	Del texto a la decisión	11
10	Discusión orientada a negocio	12
11	Conclusiones y líneas futuras	12
11.1	Conclusiones	12
11.2	Lecciones aprendidas	12
11.3	Líneas futuras	13
Anexo A	Código desarrollado y reproducibilidad	14
Anexo B	Léxico de aspectos	14
Anexo C	Análisis exploratorio ampliado	15
Anexo D	Resultados detallados	17

1 Resumen ejecutivo

Las plataformas de salud acumulan millones de opiniones escritas por pacientes que hoy apenas se explotan. Dentro de ese texto libre hay información sobre qué medicamentos funcionan, cuáles generan efectos adversos y qué preocupa realmente a quien los toma. Leer ese volumen de forma manual es inviable.

Este trabajo convierte ese texto en información accionable. Partiendo de **213.807 reseñas reales** de pacientes sobre **3.658 medicamentos** y **836 condiciones médicas**, se ha construido un sistema capaz de:

1. clasificar automáticamente si una opinión es favorable o desfavorable;
2. descubrir de qué hablan los pacientes (eficacia, efectos secundarios, posología, coste) sin definir esas categorías de antemano;
3. explicar en qué se ha basado cada decisión concreta.

El modelo seleccionado, una **máquina de vectores de soporte lineal**, alcanza un **F1 de 0,9494** y un **ROC-AUC de 0,9649** evaluado sobre **721 medicamentos que nunca aparecieron durante el entrenamiento**. Esta condición de evaluación es deliberadamente exigente y se justifica en la sección 5.2.

El modelo se ha empaquetado en una aplicación que recibe una reseña nueva y devuelve, en tiempo real, la predicción, los aspectos detectados y los términos que han pesado en la decisión.

Idea clave. El sistema permite detectar señales negativas sobre un medicamento sin leer manualmente miles de reseñas. Sobre las 213.807 opiniones analizadas, identifica automáticamente las 53.235 desfavorables y explica por qué lo son, reduciendo drásticamente el tiempo de reacción en farmacovigilancia.

2 Introducción y contexto de negocio

2.1 El problema

Cuando un paciente abandona un tratamiento, rara vez lo comunica a su médico: lo escribe en internet. Esa información existe, es pública y está sin explotar.

Las áreas de farmacovigilancia trabajan hoy con notificaciones formales de reacciones adversas, un canal fiable pero lento e infrautilizado. Las reseñas de pacientes ofrecen una señal complementaria: masiva, inmediata y espontánea. Su inconveniente es el formato —texto libre, sin estructura, con faltas de ortografía y jerga— que impide analizarlas con herramientas convencionales.

El coste de no hacerlo es doble. Por un lado, se pierde tiempo de reacción ante un problema de seguridad. Por otro, se desconoce qué mueve realmente la satisfacción del paciente, información valiosa para decidir sobre un tratamiento o priorizar la comunicación con el usuario.

2.2 Objetivos

1. **Clasificar** automáticamente el sentimiento de una reseña.
2. **Descubrir** los temas y aspectos predominantes en el corpus.
3. **Explicar** las predicciones de forma comprensible para negocio.
4. **Desplegar** el modelo en una aplicación que acepte reseñas nuevas.

2.3 Preguntas de investigación

P1 ¿Puede predecirse la satisfacción del paciente únicamente a partir del texto que escribe?

P2 ¿Generaliza el modelo a medicamentos que nunca ha visto?

P3 ¿Qué aspectos concentran la insatisfacción, y coinciden con los que cabría esperar?

La sección 8 muestra que la respuesta a P3 es contraintuitiva.

3 El conjunto de datos

3.1 Fuente, licencia y derechos de uso

Se emplea el *Drug Review Dataset* (Drugs.com), publicado en el UCI Machine Learning Repository (DOI 10.24432/C5SK5S) bajo licencia CC BY 4.0. Los autores autorizan su uso con fines de investigación, sin explotación comercial ni redistribución, y con cita del trabajo original [1]. El uso realizado en este TFM cumple íntegramente esas condiciones.

3.2 Estructura y volumen

Tabla 1: Variables del conjunto de datos.

Variable	Tipo	Descripción
drugName	Categórica	Nombre del medicamento (3.658 distintos)
condition	Categórica	Condición médica tratada (836 distintas)
review	Texto	Opinión libre del paciente
rating	Numérica	Valoración de 1 a 10
date	Fecha	Publicación, de feb. 2008 a dic. 2017
usefulCount	Numérica	Usuarios que la marcaron como útil

La longitud media de una reseña es de **84,7 palabras** (445,8 caracteres), suficiente para aplicar técnicas de NLP con garantías.

3.3 Calidad de los datos y limpieza aplicada

El fichero original presenta tres problemas que, de no corregirse, comprometerían el análisis. Se documentan aquí porque el diagnóstico de la calidad del dato es parte del trabajo, no un trámite previo.

- Codificación HTML doble.** Los apóstrofes aparecen como `'` y las reseñas van envueltas en comillas duplicadas. Sin corregirlo, la tokenización fragmenta palabras como *don't* en unidades sin sentido.
- Filas corruptas.** **1.171 registros** contienen, en el campo `condition`, fragmentos de HTML procedentes del proceso de extracción original (por ejemplo, "`3</span> users found this comment helpful`"). Se eliminan.
- Duplicados exactos.** Se detectan y eliminan **85 reseñas** idénticas en texto, medicamento y condición. Aunque son pocas, su eliminación es imprescindible: una reseña repetida a ambos lados de la partición produciría fuga de información y métricas artificialmente optimistas.

Tras la limpieza se conservan **213.807 reseñas** de las 215.063 originales. Persisten 1.194 registros sin condición asignada, que se mantienen por ser válidos para el análisis de texto.

3.4 Limitaciones y consideraciones éticas

- **Sesgo de autoselección.** Quien escribe una reseña no es un paciente medio: suele hacerlo cuando el resultado ha sido muy bueno o muy malo. La sección 4 lo confirma empíricamente.
- **Ausencia de verificación clínica.** No hay diagnóstico confirmado ni seguimiento médico detrás de cada texto.
- **Privacidad.** Las reseñas son públicas y anónimas; no contienen identificadores de pacientes.
- **Uso responsable.** El sistema es una herramienta de apoyo al análisis agregado. **No constituye consejo médico** ni sustituye el criterio clínico, y así se advierte explícitamente en la aplicación.

4 Análisis exploratorio




Figura 1: Distribución de valoraciones y reparto por sentimiento.

El hallazgo más relevante del análisis exploratorio es que **la distribución de valoraciones es marcadamente bimodal**: las puntuaciones de 10 y de 1 concentran los dos mayores volúmenes, mientras que la zona intermedia está poco poblada. La valoración media es de **6,99** y la mediana de **8**, con una desviación típica de 3,28.

Esto no es un defecto del conjunto de datos: es información. Los pacientes escriben cuando tienen algo que celebrar o algo que denunciar. Tiene dos consecuencias directas para el proyecto: justifica plantear el problema como clasificación binaria (sección 5.1) y advierte de que el modelo verá pocos ejemplos de opiniones tibias.

4.1 Contrastes estadísticos

Dos hipótesis intuitivas se han contrastado formalmente en lugar de darlas por buenas a partir de un gráfico.

¿Son más largas las reseñas negativas? La intuición dice que el descontento se explye más. Los datos dicen lo contrario: la mediana es de **86 palabras en las positivas** frente a **79 en las negativas**. La prueba de Mann-Whitney rechaza la igualdad de distribuciones con $p = 8,03 \times 10^{-90}$. La diferencia es pequeña en magnitud pero estadísticamente indiscutible: con

194.759 observaciones, casi cualquier diferencia resulta significativa, motivo por el que se reporta también el tamaño del efecto y no solo el p -valor.

¿Se perciben como más útiles las opiniones extremas? Sí. La correlación de Spearman entre valoración y número de votos de utilidad es $\rho = 0,28$, y las reseñas extremas (1, 2, 9 o 10) acumulan una media de **30,8 votos útiles** frente a **22,7** de las moderadas.

4.2 Satisfacción por condición médica




Figura 2: Condiciones con menor y mayor satisfacción declarada (mínimo 500 reseñas).

Las diferencias son grandes y clínicamente coherentes. En el extremo inferior aparecen *Vaginal Yeast Infection* (media 4,08 sobre 3.085 reseñas) y *Abnormal Uterine Bleeding* (4,38). En el superior, *Hyperhidrosis* (8,90), *Alcohol Dependence* (8,83) y *Smoking Cessation* (8,73).

El patrón sugiere que la satisfacción es alta cuando el tratamiento resuelve un problema concreto y verificable por el propio paciente, y baja en condiciones recurrentes donde el alivio es temporal.

5 Metodología

5.1 De la valoración a la etiqueta de sentimiento

Se traduce la valoración numérica en una etiqueta binaria: **positiva** si rating ≥ 7 y **negativa** si rating ≤ 4 . La banda intermedia (5–6) se descarta por ambigua.

Esta decisión tiene un coste que conviene explicitar: se apartan **19.048 reseñas** (el 8,9% del total). A cambio, las dos clases representan opiniones inequívocas y la etiqueta resultante es

fiable. El conjunto etiquetado queda en **194.759 reseñas**, con un **72,7% de positivas**: un desbalanceo moderado que obliga a no evaluar por *accuracy* y a usar `class_weight="balanced"`.

5.2 Partición: por qué una división aleatoria engaña

Una partición aleatoria permitiría que el mismo medicamento apareciese en entrenamiento y en test. El modelo aprendería el vocabulario característico de ese fármaco —los efectos concretos que produce, cómo lo nombran los pacientes— y obtendría en test una nota que no reflejaría su capacidad real.

Se ha empleado por ello una **partición agrupada por medicamento** (`GroupShuffleSplit`, 80/20). El resultado: 158.432 reseñas de entrenamiento y 36.327 de test, con **721 medicamentos que aparecen únicamente en test**.

Idea clave. Evaluar sobre medicamentos nunca vistos produce cifras más bajas que una partición aleatoria, pero son las únicas que anticipan el comportamiento real del sistema cuando llegue al mercado un fármaco nuevo.

5.3 Representación del texto

Se emplea **TF-IDF** con unigramas y bigramas, produciendo una matriz de 158.432×192.396 . Las decisiones relevantes:

- `ngram_range=(1,2)`: los bigramas capturan negaciones y expresiones compuestas ("*stopped taking*", "*weight gain*") que un unigrama pierde. Su peso en el modelo final lo confirma.
- `min_df=5` y `max_df=0.9`: descartan erratas irrepetibles y términos omnipresentes sin capacidad discriminante.
- `sublinear_tf=True`: amortigua el efecto de repetir una palabra muchas veces dentro de una misma reseña.

El vectorizador se ajusta **únicamente sobre el conjunto de entrenamiento** y se reutiliza para todos los modelos. Nunca ve el test, por lo que no existe fuga de información.

5.4 Modelos evaluados

Tabla 2: Técnicas evaluadas, con sus bondades y debilidades.

Técnica	Bondades	Debilidades
Baseline	Referencia mínima imprescindible	Sin capacidad predictiva
Naive Bayes (Complement)	Muy rápido; corrige el sesgo del NB ante clases desbalanceadas	Asume independencia entre términos, falsa en lenguaje natural
Regresión Logística	Interpretable; sus coeficientes explican la decisión	Solo capta relaciones lineales
SVM lineal	Muy eficaz en alta dimensión	No da probabilidades sin calibrar; calibrar triplica el coste
Random Forest (sobre LSA)	Capta interacciones no lineales	Exige reducir dimensionalidad; pierde interpretabilidad

Random Forest merece una nota. Aplicarlo directamente sobre 192.396 columnas dispersas resulta inviable en tiempo y rinde mal. Se le antepone una reducción de dimensionalidad mediante

TruncatedSVD a 150 componentes —Análisis Semántico Latente—, que es la práctica habitual para combinar modelos de árboles con representaciones de texto. Se limita además la profundidad de los árboles a 14 niveles: sin ese límite el entrenamiento supera los cinco minutos sin mejora apreciable.

Conviene anticipar aquí un dato que resultará decisivo en los resultados: esas 150 componentes explican únicamente el **8,4% de la varianza** original. La compresión es agresiva y, como se verá, tiene un coste.

6 Resultados

Tabla 3: Métricas sobre el conjunto de test (36.327 reseñas, 721 medicamentos no vistos).

Modelo	Accuracy	Precisión	Recall	F1	F1 macro	ROC-AUC
Baseline (clase mayoritaria)	0,7610	0,7610	1,0000	0,8643	0,4321	0,5000
Random Forest (sobre LSA)	0,8578	0,9227	0,8876	0,9048	0,8122	0,9092
Naive Bayes (Complement)	0,8594	0,9358	0,8753	0,9045	0,8189	0,9235
Regresión Logística	0,9171	0,9608	0,9291	0,9446	0,8900	0,9647
SVM lineal	0,9221	0,9379	0,9613	0,9494	0,8898	0,9649




Figura 3: Comparativa de modelos sobre el conjunto de test.

El baseline ilustra por qué no basta con la *accuracy*. Predecir siempre "positivo" alcanza un F1 de 0,8643, una cifra aparentemente buena que corresponde a un modelo sin ningún valor: su ROC-AUC es 0,5, el del azar. Toda comparación honesta debe apoyarse en ROC-AUC y F1-macro.

La **SVM lineal** obtiene el mejor F1 (0,9494) y ROC-AUC (0,9649). La Regresión Logística queda muy cerca (0,9446 y 0,9647) con una diferencia prácticamente irrelevante en la práctica, lo que resulta útil: si se priorizase la interpretabilidad directa, cambiar a Regresión Logística costaría menos de medio punto de F1.

La validación cruzada de 5 particiones sobre el entrenamiento confirma la estabilidad: $F1 = 0,9358 \pm 0,0006$.

6.1 El modelo no lineal no aporta: por qué

Random Forest queda claramente por detrás (F1 de 0,9048 y ROC-AUC de 0,9092), al nivel del Naive Bayes y a más de cuatro puntos de ROC-AUC de los modelos lineales. El resultado merece explicación, porque contradice la intuición de que un modelo más flexible debería rendir mejor.

La causa no es el algoritmo, sino la representación que se ve obligado a usar. Random Forest no puede operar sobre 192.396 columnas dispersas, de modo que antes hay que comprimir el texto a 150 componentes mediante SVD, y esa compresión **retiene apenas el 8,4% de la varianza**. El modelo trabaja, por tanto, con una versión muy empobrecida de la información: pierde exactamente los términos poco frecuentes pero muy discriminantes (*miracle*, *useless*, *ruined*) sobre los que se apoyan los modelos lineales.

Idea clave. En clasificación de texto, la capacidad de un modelo para captar relaciones no lineales importa menos que su capacidad para trabajar directamente sobre una representación dispersa de alta dimensión. La flexibilidad del algoritmo no compensa la información destruida al comprimir.

Su peor comportamiento se concentra además en la clase minoritaria: la precisión sobre reseñas negativas cae a 0,6807, frente al 0,8661 de la SVM. Dicho de otro modo, una de cada tres alertas que generaría sería falsa.

6.2 Dónde se equivoca el modelo

Las métricas agregadas esconden un desequilibrio importante entre clases:

Tabla 4: Rendimiento por clase del modelo seleccionado (SVM lineal).

Clase	Precisión	Recall	F1	Casos
Negativa	0,8661	0,7972	0,8302	8.683
Positiva	0,9379	0,9613	0,9494	27.644

El modelo es notablemente peor detectando reseñas negativas: recupera el 79,7% de ellas frente al 96,1% de las positivas. Dicho de otro modo, **una de cada cinco opiniones desfavorables pasa desapercibida**. El F1 macro (0,8898) refleja esta realidad mucho mejor que el F1 global.

Esto importa, y mucho, para el caso de uso: en farmacovigilancia el error caro es precisamente el falso negativo, la señal de alarma que no se detecta. La sección 9 explica cómo la aplicación mitiga este problema mediante un umbral de alerta configurable en lugar del 0,5 por defecto.

7 Interpretabilidad: por qué decide lo que decide

Como la SVM calibrada no expone coeficientes directamente interpretables, la explicabilidad global se calcula sobre la Regresión Logística, cuyo rendimiento es equivalente. Los términos aprendidos son un buen indicio de que el modelo capta señal real y no artefactos:

- **Hacia negativo:** *worse*, *disappointed*, *worst*, *don't recommend*, *gained*, *useless*, *horrible*, *stopped taking*, *ruined*.




Figura 4: Términos con mayor peso en la decisión del modelo.

- **Hacia positivo:** *love, amazing, miracle, changed life, saved, great, works, best, excellent.*

Obsérvese que varios de los términos más informativos son **bigramas** (*"stopped taking"*, *"changed life"*, *"don't recommend"*), lo que valida la decisión de incluirlos en la representación.

7.1 Explicación de un caso concreto

Sobre una reseña real de **Apixaban** con valoración 1, el modelo asigna una probabilidad de sentimiento positivo de **0,079**, es decir, la clasifica correctamente como negativa con alta confianza. Los términos que más pesan en esa decisión son *stop*, *developed*, *taking* y *flu*, coherentes con un relato de abandono del tratamiento por efectos adversos.

Este nivel de explicación es lo que permite que un revisor humano confíe en el sistema: no recibe un veredicto opaco, sino un veredicto con sus motivos.

8 Temas y aspectos en las opiniones

La factorización matricial no negativa (NMF) sobre TF-IDF identifica ocho temas sin ninguna supervisión. Su nitidez es notable: emergen áreas terapéuticas reconocibles sin haberlas definido.

Tabla 5: Temas descubiertos y proporción de reseñas positivas.

Tema	Términos principales	% positivas
Eficacia general	works, great, medicine works	92,7%
Ansiedad y depresión	anxiety, life, depression, panic	83,8%
Sueño	sleep, night, asleep, hours	77,3%
Peso	weight, gain, lost, pounds	77,0%
Dolor crónico	pain, relief, severe, chronic	72,6%
Dermatología	acne, skin, face, clear	72,5%
Posología	day, days, took, taking	65,6%
Anticoncepción	period, birth control, pill	63,1%




Figura 5: Temas descubiertos mediante NMF y su polaridad.

8.1 Un hallazgo contraintuitivo

El análisis por aspectos, construido sobre un léxico definido explícitamente (véase Anexo B), arroja el resultado más interesante del trabajo.

Tabla 6: Aspectos mencionados y su relación con la valoración.

Aspecto	% reseñas	Valoración si lo menciona	Si no
Eficacia	51,3%	7,58	6,69
Efectos secundarios	63,5%	7,16	7,12
Posología y administración	43,5%	7,18	7,11
Coste y acceso	7,6%	7,37	7,12

Cabría esperar que mencionar efectos secundarios fuese señal de insatisfacción. **No lo es:** la valoración media apenas varía (7,16 frente a 7,12) pese a que el aspecto aparece en el 63,5% de las reseñas. Lo que sí discrimina es hablar de **eficacia**, con una diferencia de casi un punto (7,58 frente a 6,69).

Idea clave. Los pacientes toleran los efectos secundarios cuando el medicamento funciona. Lo que determina la satisfacción no es la ausencia de efectos adversos, sino la percepción de eficacia. Un sistema de alerta que se limitase a buscar menciones de efectos secundarios generaría un enorme volumen de falsos positivos.

El cruce por condición señala dónde mirar. **Birth Control** destaca como el caso más preocupante: con 33.573 reseñas —el mayor volumen del corpus— registra la valoración media más baja del grupo (6,18), un 69,6% de menciones de efectos secundarios y solo un 31,3% de menciones de eficacia. Es exactamente el perfil que justificaría una revisión: mucho volumen, baja satisfacción y escasa percepción de que el tratamiento funcione.




Figura 6: Menciones de efectos secundarios frente a satisfacción, por condición.

9 Productivización

Un modelo que solo vive en un cuaderno de análisis no aporta valor. El modelo entrenado se ha empaquetado en una **aplicación web operativa**.

9.1 Arquitectura

La solución se serializa como un *pipeline* único (`joblib`, 289 KB) que encapsula el vectorizador y el clasificador. Esto garantiza que el texto recibido en producción atravesase exactamente las mismas transformaciones que durante el entrenamiento, eliminando la principal fuente de errores en el despliegue de modelos de NLP.

Sobre él, una interfaz en **Streamlit** expone tres funciones: predicción con probabilidad asociada, detección de aspectos y explicación local mediante LIME.

9.2 Del texto a la decisión

El recorrido de una reseña nueva es inmediato: el analista la pega, y el sistema devuelve el sentimiento previsto con su probabilidad, los aspectos detectados y los términos que han inclinado la decisión.

La aplicación incorpora un **umbral de alerta configurable** (0,35 por defecto en lugar del 0,5 habitual). Esta decisión responde directamente a la debilidad identificada en la sección de errores: al elevar la sensibilidad hacia la clase negativa se recuperan reseñas desfavorables que un umbral neutro dejaría escapar, a costa de revisar algunos falsos positivos. En farmacovigilancia, ese intercambio es claramente favorable.

10 Discusión orientada a negocio

Volumen procesable. Sobre las 36.327 reseñas de test, el sistema identifica correctamente 6.922 de las 8.683 opiniones negativas. Una revisión manual equivalente, a un ritmo conservador de dos minutos por reseña, supondría más de 1.200 horas de trabajo.

Dónde poner el foco. El análisis por aspectos redirige el esfuerzo de vigilancia: rastrear menciones de efectos secundarios es ineficiente porque aparecen en el 63,5% de las reseñas sin correlación con la insatisfacción. La señal útil está en la percepción de eficacia.

El coste del error. Con la configuración por defecto, una de cada cinco reseñas negativas pasa desapercibida. El sistema debe entenderse como un **filtro de priorización**, no como un sustituto del criterio humano: su valor está en ordenar por urgencia un volumen inabarcable, no en decidir por sí solo.

Respuesta a las preguntas planteadas. P1: sí, el texto por sí solo predice la satisfacción con un ROC-AUC de 0,9649. P2: sí, y esa cifra se obtiene precisamente sobre medicamentos nunca vistos. P3: los aspectos que concentran la insatisfacción no son los esperados, como se ha discutido.

11 Conclusiones y líneas futuras

11.1 Conclusiones

1. Es posible predecir la satisfacción de un paciente a partir exclusivamente del texto de su reseña, con un **F1 de 0,9494** y un **ROC-AUC de 0,9649** sobre medicamentos no vistos.
2. Los modelos lineales sobre TF-IDF resultan muy competitivos en esta tarea. La diferencia entre SVM y Regresión Logística es marginal, lo que permite elegir en función de la interpretabilidad deseada.
3. **Aumentar la complejidad del modelo no mejora el resultado.** Random Forest, pese a captar relaciones no lineales, queda cuatro puntos de ROC-AUC por detrás porque se ve obligado a trabajar sobre una compresión que conserva el 8,4% de la varianza. En texto, la representación pesa más que la sofisticación del algoritmo.
4. **Mencionar efectos secundarios no predice insatisfacción;** sí lo hace la percepción de eficacia. Es el hallazgo con mayor implicación práctica del trabajo.
5. El desequilibrio entre clases es la principal limitación: el modelo detecta peor lo negativo, que es justamente lo que más importa.

11.2 Lecciones aprendidas

La decisión técnica con mayor impacto no fue la elección del algoritmo, sino la **estrategia de partición**. Comprobar que una división aleatoria inflaba las métricas obligó a rehacer la evaluación y produjo cifras más bajas, pero defendibles.

La segunda lección llegó con Random Forest. Entrenarlo directamente sobre la matriz dispersa resultó inviable, y la reducción necesaria para hacerlo ejecutable acabó siendo la causa de su peor

rendimiento. Es un buen recordatorio de que una restricción computacional puede convertirse, sin advertirlo, en una limitación metodológica.

Por último, medir siempre contra un *baseline* trivial evitó un error de lectura: un F1 de 0,86 parecía un buen resultado hasta comprobar que se alcanzaba prediciendo siempre la misma clase.

11.3 Líneas futuras

- **Modelos basados en Transformers.** Un modelo tipo BERT ajustado al dominio médico debería capturar mejor la negación y la ironía, las dos fuentes de error más frecuentes.
- **Umbral optimizado por coste.** Ajustar el umbral maximizando una función de coste explícita en lugar de fijarlo heurísticamente.
- **Detección de emergentes.** Vigilar la aparición de términos nuevos asociados a un medicamento como señal temprana de un efecto adverso no documentado.
- **Extensión multilingüe,** para aplicar el sistema a corpus en español.

Referencias

- [1] Gräßer, F., Kallumadi, S., Malberg, H., Zaunseder, S. (2018). *Aspect-Based Sentiment Analysis of Drug Reviews Applying Cross-Domain and Cross-Data Learning*. International Conference on Digital Health, 121–125.
- [2] Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825–2830.
- [3] Ribeiro, M. T., Singh, S., Guestrin, C. (2016). “*Why Should I Trust You?: Explaining the Predictions of Any Classifier*”. KDD 2016, 1135–1144.
- [4] Lee, D. D., Seung, H. S. (2001). *Algorithms for Non-negative Matrix Factorization*. NIPS 13, 556–562.

Anexo A Código desarrollado y reproducibilidad

El código completo se encuentra en el siguiente repositorio:

[URL DEL REPOSITORIO]

Fichero	Contenido
src/config.py	Rutas, constantes, carga y limpieza de datos
src/eda.py	Fase 1: análisis descriptivo y contrastes
src/modelado.py	Fase 2: vectorización y comparativa de modelos
src/topics_explicabilidad.py	Fase 3: temas, aspectos y LIME
src/app.py	Fase 4: aplicación de productivización

Reproducción completa en cuatro órdenes:

```
pip install -r requirements.txt
python src/eda.py
python src/modelado.py
python src/topics_explicabilidad.py
```

Todos los procesos aleatorios emplean la semilla fija `RANDOM_STATE = 42`: partición, submuestreos, NMF, SVD, Random Forest y LIME. Las métricas se escriben en `resultados/metricas/*.json`, de modo que **cada cifra de esta memoria es trazable hasta una ejecución concreta** y puede verificarse volviendo a ejecutar el código.

Anexo B Léxico de aspectos

El análisis de la sección 8 se apoya en un léxico definido de forma explícita. Se optó por esta vía —y no por un diccionario automático— porque el objetivo era medir aspectos concretos y accionables para farmacovigilancia, no obtener categorías genéricas.

La búsqueda se realiza sobre el texto en minúsculas mediante expresiones regulares con delimitadores de palabra (`\b`), de forma que *"pain"* no active una coincidencia dentro de *"painting"*.

Aspecto	Términos
Eficacia	work, works, worked, effective, helped, help, relief, improve, improved, better, cured, results
Efectos secundarios	side, effects, nausea, headache, dizzy, dizziness, weight, gain, anxiety, insomnia, tired, fatigue, pain, sick, vomiting, rash, depression
Posología y administración	dose, dosage, mg, pill, pills, tablet, injection, daily, twice, morning, night, taper, withdrawal
Coste y acceso	price, cost, expensive, insurance, cheap, afford, pharmacy, generic, coupon

Limitación conocida. El léxico detecta la *mención* de un aspecto, no su *polaridad*: la frase "*no side effects*" cuenta como mención de efectos secundarios. Esta es, muy probablemente, una de las razones por las que dicho aspecto apenas discrimina entre reseñas satisfechas e insatisfechas (Tabla 6). Un análisis de sentimiento basado en aspectos, con detección de negación, es la extensión natural de este trabajo.

Anexo C Análisis exploratorio ampliado




Figura 7: Condiciones y medicamentos con mayor volumen de reseñas.




Figura 8: Distribución de la longitud de la reseña según el sentimiento. Base gráfica del contraste de Mann-Whitney de la sección 4.1.




Figura 9: Evolución del volumen de reseñas y de la valoración media por trimestre, de 2008 a 2017.

Anexo D Resultados detallados




Figura 10: Curvas ROC de los modelos evaluados.

Informe de clasificación por clase

Complementa la Tabla 4 con el detalle de los dos modelos extremos de la comparativa.

Modelo	Clase	Precisión	Recall	F1	Casos
SVM lineal	Negativa	0,8661	0,7972	0,8302	8.683
	Positiva	0,9379	0,9613	0,9494	27.644
Random Forest (LSA)	Negativa	0,6807	0,7632	0,7196	8.683
	Positiva	0,9227	0,8876	0,9048	27.644

El contraste es revelador: sobre la clase positiva ambos modelos son comparables, pero sobre la negativa —la que importa— Random Forest pierde 19 puntos de precisión. Confirma que la diferencia entre ambos no está en la capacidad de clasificar en general, sino en detectar la señal minoritaria.

Ficheros de métricas

Fichero	Contenido
eda_resumen.json	Estadísticos descriptivos y contrastes
modelado_resultados.json	Métricas de los 5 modelos y coeficientes
temas_y_explicabilidad.json	Temas NMF, aspectos y casos LIME